

SKALA 4기 · 판교 10반 · 2조

KV Cache 최적화 기술 평가 보고서

Long-context LLM Serving을 위한 SW·HW 접근 비교

SW - KIVI 2-bit KV cache 양자화 데이터를 작게 만드는 접근	HW - ITME CXL-hybrid 메모리 확장 답을 공간을 늘리는 접근
---	---

이휘호 · 이민서 · 오지연 · 오상현 · 목진훈 · 이은서

2026. 09. 22.

0. SUMMARY

KIVI는 tuning-free 2bit KV cache 양자화로 GPU 상의 peak memory를 최대 약 $2.6\times$ 까지 감소시키고, 이로 인해 실험 환경에서 배치 크기 최대 $4\times$ 및 처리량을 약 $2.35\rightarrow 3.47\times$ 로 개선한 연구적 결과를 제시한다. KIVI는 per-channel key / per-token value 양자화 설계와 CUDA/Triton 기반의 하드웨어 친화적 구현(디퀀타이즈·MatMul 융합 등)을 통해 런타임 오버헤드를 최소화하려는 점을 특징으로 한다 ([src_kivi](#)).

ITME는 CXL-hybrid 기반의 TB급 바이트-어드레서블 원격 메모리 확장 아키텍처로, 멀티티어 DMA 프리페칭·Remote Manager·읽기우선 I/O 스케줄러 등을 결합해 대규모 KV cache와 모델 weight의 외부화를 제안하고, 평가에서 최대 약 35.7%의 처리량 향상을 보고한다 ([src_itme](#)).

두 기술은 해결 계층이 서로 다르다. KIVI는 소프트웨어·커널 수준에서 “데이터를 작게” 만들어 기존 GPU 자원 내에서 즉시적 이득을 노리는 반면, ITME는 하드웨어·시스템 수준에서 “담을 공간을 넓혀” 물리적 메모리 한계를 극복하려는 접근이다. 각 방식은 적용 범위·비용·운영 복잡성·성능/지연 리스크 측면에서 상이한 트레이드오프를 갖는다 ([src_kivi](#)) ([src_itme](#)).

입력 자료 기반 추정으로 KIVI의 TRL은 약 4~6, ITME의 TRL은 약 4~5 범위로 제시되며(논문·프로토타입 단계의 실험적 검증 수준), 두 기술 모두 상용 대규모 운영 검증 및 광범위한 생태계 통합 증거는 제한적이다 ([src_kivi](#)) ([src_itme](#)).

1. 분석 배경

장문맥 품질 평가에는 LongBench, 서빙 메모리 관리 맥락에는 PagedAttention을 함께 활용했다 ([src_longbench](#)) ([src_pagedattention](#)).

본 평가는 Long-context LLM Serving(Cloud/Data Center 환경)의 KV cache 문제를 완화하기 위한 대표적 SW·HW 접근을 상호 비교하기 위해 수행되었다. 입력 자료는 KIVI(소프트웨어·양자화)와 ITME(CXL-hybrid 기반 하드웨어/시스템)를 중심으로 수집된 논문 발췌·프로토타입 결과·이해관계자 관점 요약이다. 평가 목적은 각 기술의 원리·한계·적용성·이해관계자별 영향 및 상호 보완 가능성을 공개 근거 범위 내에서 정리하는 것이다.

2. 대상 기술 선정

2.1 SW 기술

- KIVI: tuning-free asymmetric 2bit KV cache quantization. per-channel key 양자화와 per-token value 양자화를 조합하고, group-wise quantization 및 dequantization-행렬곱 융합 등의 GPU 친화적 구현을 제공한다. 논문과 코드 공개가 보고되어 있으며 Llama/Falcon/Mistral 계열에서 평가를 수행했다 ([src_kivi](#)).

2.2 HW 기술

- ITME: CXL-hybrid 메모리를 이용한 TB-scale 바이트-어드레서블 원격 메모리 확장 및 멀티티어 DMA 기반 프리페칭·Remote Manager·읽기우선 스케줄러 등으로 구성된 시스템 아키텍처. SK hynix CMM 및 PCIe Gen5 NVMe SSD 기반 실험과 FPGA 프로토타이핑을 통해 기능적 검증을 보고함 ([src_itme](#)).

2.3 선정 근거

- 두 기술은 서로 상반된 설계 철학(소프트웨어로 압축 vs 하드웨어로 확장)을 대표하며, 공개된 실험·구현 근거 수준이 비교적 균형을 이루어 다관점 평가에 적합하다고 판단되어 선정되었다. KIVI는 구현체·실험 결과(메모리·처리량 수치) 공개가 명확하고, ITME는 하드웨어 프로토타입·장치 기반 실험 결과가 존재한다 ([src_kivi](#)) ([src_itme](#)).

3. 기술 개요

3.1 SW 기술 원리 및 한계

원리

- KIVI는 key와 value를 서로 다른 축에서 양자화한다: key는 채널별(per-channel)로 그룹화해 큰 magnitude outlier를 국소화하고, value는 토큰 단위(per-token)로 양자화해 attention 출력의 mixer 특성을 보존한다. 또한 새 토큰은 full-precision으로 추가하고 일정 길이의 full-precision sliding window(residual)를 유지해 품질 손실을 억제한다. 구현은 그룹 크기 G (예: $G=32$), residual 길이 R (예: $R=128$)을 기본값으로 사용하고 CUDA/Triton 커널로 최적화된 경로를 제공한다 ([src_kivi](#)).

한계

- 논문 스스로 prefill·decoding 단계에서의 양자화/디양자화 오버헤드 최적화 필요성을 언급한다. 하이퍼파라미터(G , R)에 민감하며, 일부 설정($G=128$, $R=64$ 등)에서 성능 저하가 관찰된다. 특정 아키텍처(예: Falcon-7B의 multi-query attention)에서는 2bit에서 품질 저하가 있어 4bit가 요구되는 사례가 보고되었다. 또한 residual 길이와 압축률/처리량 간 트레이드오프가 존재한다 ([src_kivi](#)).

3.2 HW 기술 원리 및 한계

원리

- ITME는 CXL-hybrid 메모리를 SSD-backed 원격 메모리 풀로 활용하고, 장치 내부 프리페처·멀티티어 DMA 파이프라인(CXL-hybrid → CPU staging → GPU 메모리)을 통해 데이터 이동을 파이프라인화하여 원격 접근 지연을 마스킹한다. Remote Manager가 원격 메모리의 청크·모델 weight 관리를 중앙 오케스트레이션하며, 읽기우선 I/O 스케줄러로 NVMe 내부 경쟁을 완화하려는 설계다. 프로토타입 실험에서 처리량 개선을 보고했다 ([src_itme](#)).

한계

- NVMe SSD 내부의 쓰기/읽기 경쟁으로 인해 읽기 큐가 정체되는 등 I/O 경합 문제가 발생할 수 있고, KV 캐시 볼륨 증가 시 일부 청크가 제때 스테이징되지 않아 recomputation과 성능 변동이 관찰되었다. DRAM prefetch buffer 용량 민감도(예: 70B 모델에서 4GB prefetch buffer 사용 시 약 8% 성능 저하)와 FPGA 프로토타입 대비 실장 성능 격차(20~25%) 및 극심한 컨텐션 시 대역폭 급감 등의 실장 이슈가 보고되었다. 또한 소스코드 공개 여부·드라이버·펌웨어 세부 구현은 발췌에서 확인되지 않는다 ([src_itme](#)).

4. 관점별 평가

4.1 기술 성숙도

- KIVI: 입력 자료 기반 추정으로 TRL 약 4~6 범위(논문·코드 공개·단일 GPU 실측·LLM 워크로드 기반 평가 포함)로 판단되나, 생태계 통합(주요 서빙 프레임워크와의 공식 통합) 및 상용 운영 검증은 문헌 범위 밖이다 ([src_kivi](#)).
- ITME: 입력 자료 기반 추정으로 TRL 약 4~5 범위(FPGA 프로토타입·CMM/NVMe 실험 포함)이나, 상용 CXL-hardware 가용성·드라이버·운영 통합 수준은 제한적이며 대규모 상용 검증은 부족하다 ([src_itme](#)).

4.2 시장성

- 생태계 근거: Hugging Face의 KV cache 문서는 다양한 cache 클래스와 메모리·속도 절충을 제공하고, Micron·AMD 백서는 5세대 AMD EPYC 환경의 CXL 메모리 확장을 데이터센터 배치 선택지로 제시한다 ([src_market_hf_kv_cache](#)) ([src_market_micron_amd_cxl](#)).
- KIVI(소프트웨어): 논문 실험에서의 메모리·처리량 개선은 Cloud/Data Center의 GPU 비용 절감·서빙 효율화 요구와 정합성이 높아 수요 측면에서 잠재력이 크다. 다만 문헌에는 상용 도입 사례·정량적 TCO 절감 수치가 없어 실제 시장 채택 속도는 엔지니어링 통합·운영 검증에 의존한다 ([src_kivi](#)).
- ITME(하드웨어): 대규모 컨텍스트 수요를 겨냥한 아키텍처로 수요·정합성이 높으나, 상용 하드웨어 가용성·CAPEX·운영 복잡성(펌웨어·Remote Manager 등) 때문에 채택 장벽은 크다. 문헌은 성능 잠재력을 제시하나 장기 TCO·운영 사례는 제시하지 않는다 ([src_itme](#)).

4.3 이해관계자

- Cloud/Data Center 사업자: 단기·저비용 개선의 경우 KIVI가 현실적 파일럿 대상(소프트웨어 적용)으로 보이며, TB급 컨텍스트 필요시 ITME가 근본적 해법을 제공하나 운영·CAPEX·I/O 변동성 리스크를 사전 산정해야 한다 ([src_kivi](#)) ([src_itme](#)).
- LLM Serving 개발자: KIVI는 Hugging Face Transformers 기반 구현과 CUDA/Triton 커널을 포함하여 서빙 스택에 상대적으로 빠르게 통합 가능한 후보이나, 커널·KV manager 수준의 변경과 하이퍼파라미터 튜닝이 요구된다. ITME는 Remote Manager·I/O 스케줄러·펌웨어 연동 등 다계층 통합을 요구해 통합·유지보수 부담이 크다 ([src_kivi](#)) ([src_itme](#)).
- HW·메모리 벤더 및 OEM: KIVI는 소프트웨어적 접근으로 HBM 제약을 완화하는 즉효적 수단이며, ITME는 물리적 용량 확장과 장치·패브릭 수준 개선을 도모하므로 두 기술은 서로 보완 가능하나 각각 고유의 HW·펌웨어·관리 요구를 갖는다 ([src_kivi](#)) ([src_itme](#)).

4.4 도메인 적용성

- 평가 맥락: PagedAttention은 KV cache 파편화·중복의 서빙 맥락을, LongBench는 장문맥 수용성과 이해 품질의 구분 필요성을 보여준다 ([src_pagedattention](#)) ([src_longbench](#)).
- 지연·SLO 맥락: DistServe는 prefill과 decoding을 분리해 TTFT와 TPOT 간의 간섭을 줄이는 서빙 설계를 제시한다. 이는 KIVI·ITME의 매체 단계 최적화와는 구분되는 시스템 레벨의 비교 기준이다 ([src_distserve](#)).
- Cloud/Data Center Long-context LLM Serving:
 - KIVI는 기존 GPU 중심 인프라에서 KV 캐시의 '유효 용량'을 늘려 배치·동시성 이득을 기대할 수 있으나 TTFT/TPOT 등 지연 관련 세부 지표와 멀티-GPU·분산 서빙 환경에서의 상호작용은 입력 자료만으로 일반화하기 어렵다 ([src_kivi](#)).

- ITME는 TB급 KV 수요를 갖는 워크로드(매우 긴 문맥·대규모 동시 세션)에 적용 가능하나, I/O 스톱·DRAM prefetch 버퍼 요구·장치 내부 컨텐션 등 운영 리스크가 있어 멀티테넌트 데이터센터 적용 전 광범위한 검증이 필요하다 [src_itme].

5. 관점 간 비교 및 시사점

5.1 일치하는 평가

- 두 기술 모두 연구·프로토타입 수준에서 실험적 근거를 제시했으며(TRL 연구단계), 메모리 제약 완화→배치/컨텍스트 확장→처리량 개선이라는 동일한 목표 경로를 갖는다는 점은 일치한다. 각각은 통합·운영 비용과 특정 경로(양자화 오버헤드, NVMe 내부 경합 등)에 따른 성능 상쇄 리스크를 갖는다는 점도 공통적으로 지적되었다 [src_kivi] [src_itme].

5.2 충돌하는 평가

- 우열 충돌은 존재하지 않으나 적용 범위와 비용·즉시성 관점에서 해석 차이가 있다. KIVI는 소프트웨어 중심으로 단기간 적용 가능성을 강조하는 반면, ITME는 하드웨어 중심으로 근본적 확장을 목표로 하므로 ‘즉시성 vs 근원적 확장성’의 트레이드오프가 발생한다. 또한 KIVI는 모델별(예: Falcon-7B) 품질 민감성이 문헌에서 보고되나 ITME 문헌은 모델 품질 영향에 대한 근거를 제공하지 않아 ‘품질 리스크’ 평가의 초점이 다르다 [src_kivi] [src_itme].

5.3 시사점

- 적용 전략: 단기적·저비용 개선을 원하면 KIVI와 같은 소프트웨어 양자화 기반 접근을 먼저 파일럿 적용해 메모리·처리량 이득을 확인하되, latency-sensitive 경로의 prefill/decoding 오버헤드 측정과 모델별 품질 민감도 검증을 병행해야 한다. 장기적·근본적 확장이 필요하거나 로컬 메모리로 수용 불가능한 TB급 KV 요구가 명확하면 ITME와 같은 CXL-hybrid 기반 확장 아키텍처를 병행 검증하되 장치·펌웨어·Remote Manager·I/O QoS 등에 대한 사전 검증이 필수다 [src_kivi] [src_itme].
- 병행 운용 가능성: 입력 근거는 KIVI(로컬 압축)와 ITME(원격 확장)를 조합하는 시나리오를 현실적 옵션으로 시사하나, 두 기술을 통합 운용했을 때의 실효성(성능·지연·TCO) 및 구현 복잡도는 공개 근거만으로 확인하기 어렵다. 따라서 병행 운용은 추가 실험·현장 검증이 선행되어야 한다.

6. 분석 한계

6.1 공개 정보 기반 추정의 한계

- 근거 범위 제한: 본 보고서는 제공된 발췌·요약 자료만을 사용해 작성되었으며, 많은 실무적 세부(예: KIVI의 multi-GPU/분산 서빙 행동, 특정 GPU 모델(H100 등)에서의 end-to-end latency 수치, ITME의 소스코드·드라이버·펌웨어 구현 세부, 대규모 멀티벤더 상호운용성 테스트 결과, 장기간 TCO 비교 수치 등)는 입력 자료에 포함되어 있지 않다. 이러한 항목에 대해서는 “공개된 근거로 확인하기 어렵다.”고 명시한다.
- 실험 조건·지표 불균형: KIVI의 메모리·throughput 개선치(예: $2.6\times$ 메모리 감소, $2.35\rightarrow 3.47\times$ 처리량)와 ITME의 처리량 개선(최대 35.7%)은 서로 다른 실험 조건·지표 단위를 전제로 보고되었으므로 동일 기준에서 직접 비교할 수 없다 [src_kivi] [src_itme].
- TRL 표현 주의: TRL 수치는 입력 자료의 실험·프로토타입 근거에 기반한 추정 범위일 뿐이며, 확정적 등급으로 해석해서는 안 된다 [src_kivi] [src_itme].

- 미확인·비공개 항목: 프레임워크 통합(예: vLLM과의 공식 통합), 운영 도구(운영·모니터링·RAS) 공개, 드라이버/펌웨어 세부, 실장(프로덕션) 성능 장기 추적 데이터 등은 발췌에서 확인되지 않아 해당 항목들에 대한 판단은 불가능하다(공개된 근거로 확인하기 어렵다).

6.2 확증편향 방지 방법

- 가설 검증에 기반한 실험 설계 권고: 기술 선택·도입 시 내부 파일럿에서 A/B 테스트(예: 동일 HW·동일 워크로드에서 KIVI 적용군 vs 미적용군, ITME 프로토타입 환경에서의 스테이징 테스트)를 수행하고, 지표는 throughput(tokens/sec 등), latency(TTFT/TPOT 분리 측정), 품질(업무별 정확도 지표), 자원 사용(GB 단위 HBM/DRAM 사용), 운영 변동성(읽기 지연·I/O 스톱 빈도) 등으로 명확히 정량화하라.
- 교차검증 데이터 수집: 멀티-GPU·분산 서버, 다양한 모델 아키텍처(예: multi-query vs multi-head), 다양한 하드웨어(A100/H100 등)에서 교차검증을 수행해 모델별·하드웨어별 민감도를 확인하라.
- 블라인드 비교 및 외부 검증: 내부 평가에 편향이 개입될 위험을 줄이기 위해 실험 설계와 결과를 독립 팀 또는 외부 파트너와 공유해 교차검증을 수행하라.
- 점진적 도입과 관측: 운영 도입은 Canary 배포·점진적 롤아웃을 통해 실서비스 영향(특히 latency-sensitive 경로)을 관측하고, 모니터링·알림·롤백 체계를 마련하라.
- 문서화된 가정 명시: 모든 비용·성능 추정은 실험 조건·가정(하드웨어 구성, 워크로드 특성, 하이퍼파라미터 설정 등)을 명확히 문서화해, 조건 변경 시 재평가가 가능하도록 관리하라.

7. REFERENCE

논문

- Zirui Liu, Jiayi Yuan, Hongye Jin, et al. (2024). KIVI: A Tuning-Free Asymmetric 2bit Quantization for KV Cache. arXiv preprint. <https://arxiv.org/pdf/2402.02750>
- Hakbeom Jang, Younghoon Min, Sunwoong Kim, et al. (2026). ITME: Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories. arXiv preprint. <https://arxiv.org/pdf/2606.12556>
- Yushi Bai, Xin Lv, Jiajie Zhang, et al. (2024). LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding. arXiv preprint. <https://arxiv.org/abs/2308.14508>
- Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, et al. (2023). Efficient Memory Management for Large Language Model Serving with PagedAttention. Proceedings of the 29th Symposium on Operating Systems Principles. <https://arxiv.org/abs/2309.06180>
- Yinmin Zhong, Shengyu Liu, Junda Chen, et al. (2024). DistServe: Disaggregating Prefill and Decoding for Goodput-optimized Large Language Model Serving. OSDI 2024. <https://arxiv.org/abs/2401.09670>

기타(웹·백서)

- Hugging Face(2026-09-22). KV cache strategies. Transformers v4.57.0 documentation, https://huggingface.co/docs/transformers/v4.57.0/kv_cache
- Micron Technology and AMD(2025-07). Optimized for Data Centers: Deployment-ready CXL Memory Expansion with 5th Gen AMD EPYC. Micron white paper, <https://my.micron.com/content/dam/micron/global/public/products/white-paper/optimized-for-data-centers-micron-amd.pdf>